

项目申请书

1. 基本信息

- **项目名称:** 面向复杂问答的结构感知 GraphRAG 引擎
- **项目导师:** 姚中强
- **申请人:** 白玉韬
- **日期:** 2026 年 8 月 13 日
- **联系方式:** azrmedit0x@163.com

2. 项目背景与目标

- **背景** 随着大语言模型在知识问答、智能搜索等场景中的广泛应用，检索增强生成 (RAG) 已成为降低幻觉、引入外部知识的重要手段。现有 RAG 系统多依赖向量相似度或关键词匹配进行文本召回，在处理跨实体、多跳关系和证据分散的复杂问题时，容易遗漏关键中间实体或召回大量语义相似但无法共同支撑答案的文本。GraphRAG 通过图结构组织实体、关系和文档，可有效补充纯文本检索的不足。GeaFlow 已具备图数据建模、存储、查询与计算能力，其 geaflow-ai 模块也提供了图实体、Embedding 索引和子图搜索等基础能力，但仍缺乏面向复杂问答的统一数据映射、多路召回、图扩展、证据组织、路径追踪及标准化评测能力，亟需构建完整的结构感知 GraphRAG 检索引擎。
- **目标** 本项目拟在 GeaFlow 上设计并实现一个可解释、可配置、可复现的结构感知 GraphRAG 检索引擎，建立从原始文档到图实体和文本块的多层次统一映射，实现向量检索、BM25 检索与实体锚点识别相结合的多路召回，并以锚点为起点进行受预算约束的 1~2 跳图扩展，通过合并去重、重排序和结构化结果输出，形成包含证据正文、图路径、来源引用和分阶段得分的检索结果。引擎支持 Vector-only、Graph-only 和 Hybrid 三种可比较检索模式，并接入 HotpotQA 和 2WikiMultiHopQA 等公开多跳问答数据集，构建端到端评测流程，报告证据召回率、答案 EM/F1、路径命中率、延迟及 Token 成本等指标，同时输出完整的查询追踪链路。最终形成一套面向复杂问答的 GraphRAG 检索能力，为 GeaFlow 在知识问答、智能搜索和大模型知识增强等场景中提供可复用的基础组件。

3. 技术方法与可行性

核心技术方案

1. 统一证据模型与可追溯数据映射

- 建立原始文档、文本块、实体、图顶点和图边之间的稳定映射关系，定义 `SourceDocument`、`TextChunk`、`EntityRef`、`GraphVertexRef`、`GraphEdgeRef` 和 `Evidence` 等核心数据模型。
- 所有检索通道 (BM25、向量、图) 返回的候选结果均可转换为统一的 `Evidence` 对象，同一证据在多路召回中被合并为单条记录，同时保留各通道的原始得分和来源信息。
- 每个图检索命中结果必须输出完整的追踪链路: `query` $\rightarrow$ `selectedMode` $\rightarrow$ `seed` $\rightarrow$ `relation path` $\rightarrow$ `evidence` $\rightarrow$ `source document`，确保检索结果可解释可验证。

2. 多路召回与预算约束的图扩展

- 实现 BM25 检索 (基于现有 Lucene 依赖)、向量检索 (接受预计算向量输入，不依赖特定服务) 和实体锚点识别 (基于规范化名称、别名及高排序文本块中的实体) 三种召回通道。
- 以识别到的实体锚点为起点，进行受预算约束的 1~2 跳图扩展。图扩展通过以下机制控制成本：
 - **边扫描预算与邻居采样上限:** 不物化高顶点的完整邻接表，按关系类型优先级排序后，使用确定性采样策略 (基于查询、种子、顶点、邻居及配置随机种子的稳定哈希) 截断邻接边。
 - **图检索路径: 关联域扩散控制:** 计算前沿增长率 $\text{growthRate}(h) = \text{newUniqueVertices}(h) / \max(1, \text{frontierSize}(h-1))$ 和边际证据产出率 $\text{marginalYield}(h) = \text{newEvidenceCount}(h) / \max(1, \text{edgesExamined}(h))$ ，当增长率超过扩散阈值、边际产出低于下限或剩余路径低于最低关联分数时，提前终止扩展。
 - **版本化图视图:** 索引构建时生成不可变图快照加版本化增量覆盖的视图，查询记录观测到的图版本，确保结果可复现。增量更新仅影响受修改的块、实体、边及其局部度统计，不触发全量图重算。

3. 执行模式与可插拔融合策略

- 支持三种执行模式: **顺序执行** (通道按序运行，已完成结果可指导后续阶段)、**并行执行** (文本/向量/图通道在固定阶段预算内并发执行)、**级联执行** (低成本的 BM25/向量探针产生锚点和在线统计后，再决定是否进行图扩展、融合、重排序和最终截断)。
- 统一融合流程: 将所有通道候选转换为公共 `Evidence` 模型 $\rightarrow$ 按稳定证据 ID 及规范化源/块身份去重 $\rightarrow$ 保留各阶段原始得分和排序 $\rightarrow$ 使用可配置权重的倒数排名融合 (默认) 或可插拔的融合策略 $\rightarrow$ 调用可选的重排序器 $\rightarrow$ 按输出候选数和 Token 预算截断最终结果。
- 相同的数据分片、预算配置和结果协议下运行所有模式，保证实验结果可比较。

4. 自适应路由策略

- 路由策略与检索执行逻辑完全解耦。策略通过不可变的 `RoutingContext` (包含规范化查询特征、探测器结果、可用索引、图统计、硬预算及配置版本) 生成 `RetrievalPlan` (声明选择的检索模式、执行模式、通道顺序、各通道预算分配、`topK`、`maxHop`、融合权重、采样上限及停止规则)。
- 实现确定性规则策略作为强制基础实现：基于查询长度、平均查询词 IDF、首阶段得分差、实体锚点数量/置信度、平均候选顶点度、图扩展增长率等特征进行规则决策。例如：高平均 IDF 且 BM25 得分差大时偏向 BM25；多强锚点且平均度可控时启用图增强混合检索并允许两跳扩展；前沿增长率超过扩散阈值时停止图扩展并保留已完成结果。
- 支持可选的受约束重规划：在配置的阶段边界处，基于已消耗预算、完成阶段指标、当前证据产出率、前沿度统计和图增长率等信息，调整后继续执行策略，但不可中断已在进行中的候选操作。配置 `maxReplanCount` 防止策略循环。
- 每条查询记录所选的策略 ID/版本、上下文特征、生成的计划、校验调整、重规划事件及原因码，确保路由决策可审计、可复现。

5. 统一预算模型与可量化成本报告

- 支持三类硬约束预算（每次基准运行选择一个主要约束）：端到端延迟上限、候选评估数上限、上下文 Token 数上限。
- 对所有检索通道统一记录和报告次级成本指标：原始候选评分数量、去重后证据候选数、图边扫描数、图邻居采样数、到达顶点数、保留 Token 数、各阶段延迟及总延迟，确保图检索的隐式成本（扫描大量前沿但仅返回少量候选的情况）可量化对比。
- 使用版本化的 `TokenEstimator` 估算 Token 成本，基准配置固定估算器版本以保证成本可复现。所有检索模式在相等预算条件下进行比较，包括与等预算的纯向量过取（Vector Overfetch）基线对比。

6. 端到端评测框架

- 接入 HotpotQA (官方 distractor 设置) 和 2WikiMultiHopQA (官方开发/测试集) 两个公开多跳问答数据集。
- 构建确定性数据流水线：下载 → 校验 SHA-256 → 清洗 → 分块 → 实体抽取 → 图模式构建 → 向量生成 (来源固定) → 索引构建，所有步骤记录预处理版本、分块配置、图模式版本、向量来源及随机种子。
- 评测指标包括：证据召回率 (Evidence Recall@K)、MRR 和 NDCG、答案 EM/F1 或准确率、关系路径命中率、P50/P95 延迟、候选数、图边扫描数、Token 成本。
- 必须完成六种模式的对比：BM25-only、Vector-only、Graph-only、Fixed Hybrid、Adaptive Hybrid 及等预算 Vector Overfetch。若 Adaptive Hybrid 未显著优于 Vector-only 和等预算过取基线，报告须保留完整的负结果、消融实验及适用边界分析。

7. 失败与降级

- 缺少必需索引：单通道模式返回类型化索引错误；混合模式使用配置中可用通道继续执行并记录降级。
- 空查询：在进入检索阶段前直接拒绝。
- 无可靠实体锚点：Graph-only 返回结构化空结果；混合模式跳过图扩展继续执行。
- 预算在阶段执行中耗尽：停止消费新候选，保留已完成证据。
- 阶段异常：记录异常类别，仅当存在显式配置的降级策略时应用降级。

技术栈

- 编程语言**：Java 8+ (核心引擎，利用现有 GeaFlow 图建模、存储、查询能力及 Lucene 依赖)、Python 3.x (数据准备、基准运行脚本、结果评估与报告生成)
- 核心依赖**：Apache GeaFlow (图数据建模、图存储、图查询与图计算能力)、Lucene 8.11.2 (BM25 索引)
- 核心知识**：检索系统设计 (BM25、向量检索、倒排索引)、图论与图遍历算法 (BFS、关联域扩散控制)、分布式图计算框架概念、预算感知的查询执行、可解释检索系统设计

可行性

- 个人能力**：我熟悉 Java 和 Python 编程语言，能够阅读并扩展 GeaFlow 等现有 Java 模块；具备 RAG 系统的基本原理知识，能够承担从数据导入、索引构建到检索评测的全链路开发工作。同时，我具备数据库系统的基本理解，能够设计预算约束下的多路召回、候选去重、排序融合和性能测量方案，并对多跳问答评测 (Evidence Recall、Answer EM/F1 等指标) 有充分了解。
- 社区项目关联**：
 - a. **技术方向契合**：本项目聚焦的自适应混合检索 (融合 BM25、向量检索与图扩展) 是 GeaFlow 社区当前希望补齐的能力方向。GeaFlow 已具备图建模、存储和查询能力，`geaflow-ai` 模块也提供了图实体、索引和子图搜索基础，本项目在此基础上实现统一证据映射、多路召回、预算控制和自适应路由，与社区规划高度一致。此外，已经有很多主流 RAG 系统实现 BM25、向量检索等实现，社区已积累大量相关实践经验可供参考。
 - b. **问题价值显著**：现有 RAG 系统在处理跨实体、多跳关系和证据分散的复杂问答时，单纯依赖文本检索容易遗漏关键中间证据，而图检索能够有效补充，但其扩散成本难以控制。本项目提出的受预算约束的自适应混合检索方案，直接回应了这一实际痛点，在知识问答、智能搜索和企业知识增强等场景中具有明确的应用价值，且不依赖付费模型 API 或 GPU，具备良好的可复现性和落地条件。

4. 主要实施内容与预期产出

1. **技术设计文档**: 包含统一数据模型 (`SourceDocument`、`TextChunk`、`EntityRef`、`Evidence` 等)、检索 API 设计、预算模型、自适应策略接口、执行模式 (串行/并行/级联) 和 Trace 规范。
2. **数据导入与索引构建模块**: 提供可复现的 ingestion 流水线, 支持至少两个固定数据集 (HotpotQA、2WikiMultiHopQA) 的清洗、分块、实体抽取、图构建、BM25 索引和向量索引生成, 并输出版本化的元数据。
3. **多路检索引擎实现**:
 - BM25 检索 (基于 Lucene)、向量检索 (接受预计算向量)、实体锚点识别与 1~2 跳受预算约束的图扩展。
 - 支持 BM25-only、Vector-only、Graph-only、Fixed Hybrid、Adaptive Hybrid 五种模式及串行/并行/级联执行。
 - 实现候选融合、去重、可插拔重排序接口、预算截断和 Trace 生成。
4. **自适应策略与评测框架**:
 - 实现确定性规则自适应策略 (基于查询长度、平均 IDF、得分差、候选平均度、图增长率等特征)。
 - 端到端评测脚本 (Python): 计算 Evidence Recall@K、MRR/NDCG、Answer EM/F1、路径命中率、延迟分布、Token 成本等指标, 并输出对比报告。
5. **完整 Benchmark 实验报告**:
 - 在固定预算下对比六种方法 (BM25、Vector RAG、Graph-only、Fixed Hybrid、Adaptive Hybrid、等预算 Vector Overfetch)。
 - 提供不同预算级别和查询类别的消融分析、失败案例及适用边界讨论。
6. **源码、测试与文档**: 包含 Java API 示例、单元测试 (JUnit)、端到端集成测试、设计文档、用户手册和原始实验结果及运行脚本。

5. 时间线 (2026 年 9 月 1 日 – 2026 年 11 月 30 日, 共 3 个月)

第一阶段: 设计与基础构建 (9 月 1 日 – 9 月 30 日, 约 4 周)

- 完成技术设计文档, 确定数据模型、API 契约、预算模型和 Trace 格式 (产出 1)。
- 实现数据导入流水线: 固定数据集下载与校验、清洗分块、实体抽取、图结构构建, 输出版本化元数据, 进行预实验。(产出 2 前期)。
- 搭建 BM25 (Lucene) 和向量检索的基础骨架, 完成接口定义。

第二阶段: 核心检索与融合实现 (10 月 1 日 – 10 月 31 日, 约 4 周)

- 完成 BM25、向量检索和实体锚点识别模块 (产出 3 前期)。
- 实现预算约束的 1~2 跳图扩展 (边扫描限制、确定性采样、扩散停止条件)。
- 实现候选融合、去重、预算截断、可插拔重排序接口及五种检索模式、三种执行模式 (产出 3 完成)。
- 实现自适应规则策略及特征提取器 (产出 4 前期)。

第三阶段: 评测框架与实验报告 (11 月 1 日 – 11 月 30 日, 约 4 周)

- 完成端到端评测脚本: Evidence 组织、抽取式答案评估、指标计算 (产出 4 完成)。
- 在两个固定数据集上运行全量 Benchmark, 完成六种方法对比及消融实验 (产出 5)。
- 撰写实验报告, 整理负向结果与适用边界分析。
- 补充单元测试、集成测试、文档和示例 (产出 6), 进行 Bug 修复与项目收尾。

时间余量说明: 各阶段预留部分缓冲时间用于应对数据兼容、性能调优和测试修复, 确保在 11 月底前完成全部交付。

6. 个人期望

本项目计划于 2026 年 9 月至 11 月进行, 正值我大四上学期, 时间充裕且具备扎实的 Java/Python 开发基础和检索/图算法理论知识。通过参与该项目, 我希望能够深入理解 RAG 系统中多路召回与图检索的工程挑战, 掌握预算感知的自适应检索设计方法, 积累从数据处理、索引构建到评测对比的全链路实践经验。同时, 我也期望通过与 GeaFlow 社区的协作, 提升对开源项目开发流程和社区规范的理解, 为未来从事数据系统与智能信息检索方向的学术研究或工业落地打下坚实基础。